

باید از همان ابتدا یک تفکیک اساسی را قفل کنی:

PCA و UMAP روش‌های Dimensionality Reduction هستند.

DBSCAN و GMM روش‌های Clustering هستند.

پس این چهار تا رقیب مستقیم هم نیستند. خیلی وقت‌ها اتفاقاً در یک pipeline کنار هم استفاده می‌شوند:

$$X_{\text{high-dimensional}} \rightarrow PCA/UMAP \rightarrow DBSCAN/GMM$$

حالا از پایه تا سطح مصاحبه می‌رویم.

بخش اول — PCA

1. PCA دقیقاً چیست؟

PCA = Principal Component Analysis

PCA یک روش خطی، بدون نظارت و آماری برای کاهش ابعاد است.

هدف اصلی آن این است:

یک دستگاه مختصات جدید پیدا کند که محور اول بیشترین واریانس داده را توضیح دهد، محور دوم بیشترین واریانس باقی‌مانده را، محور سوم بعد از آن و الی آخر.

این محورهای جدید را می‌گوییم:

- PC1
- PC2
- PC3
- ...

یا:

2. چرا اصلاً PCA لازم است؟

فرض کن dataset تو 100 feature دارد:

$$X = (x_1, x_2, \dots, x_{100})$$

اما بسیاری از feature ها strongly correlated هستند.

مثلاً:

- Weight
- BMI
- Waist circumference
- Body volume

همگی مقداری اطلاعات مشترک دارند.

پس شاید این 100 feature در واقع فقط 10-20 جهت اطلاعاتی مهم داشته باشند.

PCA سعی می‌کند:

$$100 D \rightarrow 10 D$$


در حالی که مقدار زیادی از information/variance را نگه دارد.

3. مثال شهودی PCA

فرض کن دو feature داریم:

- Height
- Weight

و داده‌ها تقریباً این شکلی‌اند:




Height و Weight correlated هستند.

اگر محورهای عادی را استفاده کنیم دو dimension داریم:

$$x = Height$$

$$y = Weight$$

ولی PCA یک محور مورب پیدا می‌کند:



بیشتر variation روی PC1 قرار دارد.

پس شاید بتوانیم:

$$2D \rightarrow 1D$$

بدون از دست دادن اطلاعات زیاد.

4. PCA از نظر ریاضی چه می‌کند؟

فرض کن:

$$X \in R^{n \times p}$$

که:

• n = تعداد samples

• p = تعداد features

مثلاً:

$$1000 \times 50$$

یعنی 1000 نمونه و 50 feature.

مرحله اول: Centering

برای هر feature میانگین را کم می‌کنیم:

$$X_c = X - \mu$$

تا میانگین هر feature تقریباً صفر شود.

مرحله دوم: Covariance Matrix

محاسبه می‌کنیم:

$$C = \frac{1}{n-1} X_c^T X_c$$

این covariance matrix نشان می‌دهد feature ها چطور با هم تغییر می‌کنند.

Eigen Decomposition: مرحله سوم

حل می‌کنیم:

$$Cv = \lambda v$$

که:

- v = eigenvector
- λ = eigenvalue

در PCA:

Eigenvector ها جهت Principal Components هستند.

و:

Eigenvalue میزان variance موجود در آن جهت را نشان می‌دهد.

مثلاً:

Component	Eigenvalue
PC1	8.1
PC2	3.5
PC3	1.2
PC4	0.2

PC1 بیشترین اطلاعات را دارد.

5. Explained Variance چیست؟

یکی از مهم‌ترین مفاهیم PCA.

فرض کن:

PC1 = 55%

PC2 = 25%

PC3 = 12%

PC4 = 5%

PC5 = 3%

یعنی PC1 به تنهایی:

55 %

از variance کل را توضیح می‌دهد.

PC1+PC2:

55+25=80 %

و سه component اول:

92 %

پس می‌توانیم 5 dimension را به 3 کاهش دهیم و 92% variance را حفظ کنیم.

در sklearn:

`pca.explained_variance_ratio_`

6. فرمول Explained Variance Ratio

اگر eigenvalue های PCA این‌ها باشند:

$$\lambda_1, \lambda_2, \dots, \lambda_p$$

برای PC اول:

$$EV R_1 = \frac{\lambda_1}{\sum_{j=1}^p \lambda_j}$$

مثلاً:

$$\lambda = (6, 3, 1)$$

مجموع:

$$10$$

پس:

$$PC1 = 60\%$$

$$PC2 = 30\%$$

$$PC3 = 10\%$$

7. PCA در عمل معمولاً با SVD انجام می‌شود

در implementation های واقعی معمولاً مستقیم covariance matrix را eigen-decompose نمی‌کنند.

از:

Singular Value Decomposition

استفاده می‌شود:

$$X = U S V^T$$

در اینجا ستون‌های V جهت principal components را می‌دهند.

Scikit-learn نیز معمولاً بسته به solver و ابعاد داده از روش‌های مبتنی بر SVD استفاده می‌کند.

8. Principal Component خودش چیست؟

نکته‌ای که خیلی در مصاحبه پرسیده می‌شود.

PC1 یکی از featureهای قبلی نیست.

مثلاً:

$$PC_1 = 0.61x_1 + 0.42x_2 - 0.51x_3 + 0.09x_4$$

یعنی یک **linear combination** از featureهای اصلی است.

پس PCA:

Feature selection ❌ نیست.

بلکه:

Feature extraction ✅ است.

9. Loadings چیست؟

ضرایب featureهای اصلی در Principal Component را معمولاً **loadings** می‌نامیم.

مثلاً:

$$PC_1 = 0.7Weight + 0.65BMI + 0.08Age$$

می‌توانیم نتیجه بگیریم که PC1 عمدتاً با:

- Weight
- BMI

مرتبط است.

10. یک نکته درباره علامت PCA

فرض کن:

$$PC_1 = 0.7x_1 + 0.6x_2$$

ممکن است implementation دیگری بدهد:

$$PC_1 = -0.7x_1 - 0.6x_2$$

این دو از نظر PCA equivalent هستند.

جهت eigenvector می‌تواند برعکس شود.

پس sign به خودی خود اهمیت ندارد؛ روابط نسبی مهم‌اند.

11. PCA چه زمانی مناسب است؟

PCA بسیار مناسب است وقتی:

حالت 1 — تعداد featureها زیاد است

مثلاً:

500 features

حالت 2 — Featureها correlated هستند

مثلاً biological measurements.

حالت 3 – می‌خواهی noise را کم کنی

اگر dimensions کم‌اهمیت عمدتاً noise باشند.

حالت 4 – Visualization

مثلاً:

$$100 D \rightarrow 2 D$$

هرچند برای nonlinear structure معمولاً UMAP بهتر است.

حالت 5 – قبل از clustering

مثلاً:

768D embeddings

↓

PCA

↓

50D

↓

DBSCAN

12. PCA چه زمانی مناسب نیست؟

اگر structure داده strongly nonlinear باشد.

مثلاً:

Swiss Roll

فرض کن نقاط روی یک صفحه پیچیده‌شده قرار دارند.

از نظر فضای 3D این نقاط پیچیده‌اند ولی intrinsically ممکن است 2D باشند.

PCA چون linear است نمی‌تواند آن manifold را به‌درستی باز کند.

UMAP ممکن است بهتر باشد.

13. Scaling قبل از PCA

بسیار مهم.

فرض کن:

Age	18–80
Income	5,000–500,000
Score	0–1

Variance مربوط به Income بسیار بزرگ‌تر است.

PCA ممکن است تقریباً فقط Income را ببیند.

بنابراین معمولاً:

```
from sklearn.preprocessing import StandardScaler
X_scaled = StandardScaler().fit_transform(X)
```

بعد:

PCA()

اما همیشه باید Standardize کنیم؟

نه.

اگر همه features:

- یک unit داشته باشند
- scale آن‌ها ذاتاً معنی داشته باشد

ممکن است scaling لازم نباشد.

ولی در tabular heterogeneous data:

Standardization قبل از PCA تقریباً default منطقی است.

14. مهم‌ترین Hyperparameter در PCA

n_components

مثلاً:

```
PCA(n_components=10)
```

یعنی 10 PC نگه دار.

یا:

```
PCA(n_components=0.95)
```

یعنی به اندازه‌ای component نگه دار که:

95 %

variance حفظ شود.

15. چطور تعداد Components را انتخاب کنیم؟

چند روش داریم.

روش 1 — Cumulative Explained Variance

مثلاً:

Components	Cumulative variance
1	42%

Components	Cumulative variance
2	65%
3	78%
5	89%
8	95%
10	97%


اگر threshold تو 95% باشد:

$$n=8$$

انتخاب می‌کنی.

روش 2 — Scree Plot

Eigenvalue ها را رسم می‌کنیم:



نقطه elbow می‌تواند تعداد components مناسب را نشان دهد.

روش 3 — Downstream Performance

گاهی بهترین روش همین است.

مثلاً:

PCA dimensions → clustering quality

10D → 0.52 silhouette
20D → 0.61
30D → 0.65
50D → 0.63

پس 30D ممکن است بهتر باشد.

16. آیا 95% variance همیشه بهترین انتخاب است؟

نه.

این یک heuristic است.

یک اشتباه خطرناک:

High variance = همیشه useful information

این گزاره لزوماً درست نیست.

ممکن است feature با variance کم برای separation cluster بسیار مهم باشد.

مثلاً:

Feature A → huge variance but irrelevant
Feature B → tiny variance but separates disease/control

PCA ممکن است Feature B را ضعیف کند.

17. Whiten در PCA چیست؟

در sklearn:

`PCA(whiten=True)`

PCA components علاوه بر decorrelation، طوری scale می‌شوند که variance تقریباً واحد داشته باشند.

یعنی:

PC1 variance → 1
PC2 variance → 1
PC3 variance → 1

این ممکن است برای بعضی مدل‌ها مفید باشد.

اما اطلاعات relative variance component را از بین می‌برد.

Default:

`whiten=False`

معمولاً انتخاب امن‌تری است.

18. چگونه بفهمیم PCA خوب عمل کرده؟

این بخش مهم است.

معیار 1 — Explained Variance Ratio

مثلاً:

95 %

variance با 20 component از 300 feature.

خوب است.

معیار 2 — Reconstruction Error

بعد از PCA می‌توانیم داده را reconstruct کنیم:

$$X \rightarrow Z \rightarrow \hat{X}$$

و:

$$MSE = \frac{1}{N} \sum (X - \hat{X})^2$$

هرچه reconstruction error کمتر باشد، اطلاعات بیشتری حفظ شده.

معيار 3 — Downstream Performance

مثلاً:

without PCA:
Silhouette = 0.43

with PCA:
Silhouette = 0.62

يا برای classifier:

F1 before PCA = 0.89
F1 after PCA = 0.90

معيار 4 — Stability

اگر با perturbation های کوچک components کاملاً عوض شوند، ممکن است structure ضعیف باشد.

19. محدودیت‌های PCA

PCA:

- linear است.
- به outlier حساس است.
- به scale حساس است.
- variance را information فرض می‌کند.
- PC ها همیشه interpretability ساده ندارند.
- nonlinear structure را خوب بازنمایی نمی‌کند.

20. PCA در یک جمله مصاحبه‌ای

PCA is an unsupervised linear dimensionality-reduction technique that projects data onto orthogonal directions of maximum variance, allowing us to retain most of the information using fewer dimensions.

21. UMAP چیست؟

UMAP = Uniform Manifold Approximation and Projection

یک الگوریتم:

nonlinear dimensionality reduction

است.

بیشترین کاربرد آن:

- High-dimensional data visualization
- Representation exploration
- Manifold learning
- Sometimes preprocessing before clustering

است.

22. تفاوت فلسفه PCA و UMAP

PCA می‌گوید:

جهتی پیدا کن که بیشترین variance داشته باشد.

UMAP می‌گوید:

اگر دو sample در فضای high-dimensional همسایه‌اند، سعی کن در فضای low-dimensional هم همسایه باقی بمانند.

پس UMAP بیشتر روی:

Neighborhood structure

تمرکز دارد.

23. Manifold یعنی چه؟

این مفهوم برای فهم UMAP مهم است.

فرض کن نقاط در 3D روی سطح یک کاغذ پیچیده قرار گرفته‌اند:



فضای خارجی:

$3D$

است.

ولی خود سطح intrinsically:

$2D$

است.

Manifold hypothesis می‌گوید:

High-dimensional data ممکن است روی یک ساختار با intrinsic dimensionality پایین تر قرار گرفته باشد.

مثلاً یک embedding با:

768 dimensions

شاید اطلاعات معنایی واقعی اش روی manifold بسیار کم بعدتری باشد.

24. UMAP در سطح الگوریتم چه می‌کند؟

سه مرحله اصلی دارد.

مرحله 1 — Nearest Neighbors

برای هر point نزدیک ترین همسایه ها را پیدا می‌کند.

مثلاً:

A → B, C, D
B → A, D, E
...

مرحله 2 — Graph

از data یک weighted graph می‌سازد.

هر sample:


Node

و neighborhood relationships:

Edges

هستند.

مثلاً:




وزن edge نشان می‌دهد دو نقطه چقدر strongly connected هستند.

مرحله 3 — Low-dimensional Representation

UMAP در 2D یا 3D نقطه‌ها را طوری قرار می‌دهد که neighborhood graph تا حد امکان حفظ شود.

مثلاً:



25. کمی دقیق‌تر: Local connectivity

برای هر UMAP distance i ، point های local را بررسی می‌کند.

به شکل ساده یک similarity شبیه:

$$p_{ij} \approx \exp\left(-\frac{d(i,j) - \rho_i}{\sigma_i}\right)$$

می‌سازد.

ρ_i تقریباً local connectivity adjustment و σ_i local scale است.

در نهایت neighbor relationship ها به صورت probabilistic/fuzzy graph ساخته می‌شوند.

بعد در low-dimensional space یک graph جدید ساخته می‌شود و UMAP تلاش می‌کند mismatch این دو را با تابعی شبیه cross-entropy کمینه کند.

برای مصاحبه لازم نیست این فرمول را حفظ کنی، ولی باید مفهوم را بدانی:

UMAP constructs a weighted nearest-neighbor graph in the original space and optimizes a low-dimensional embedding that preserves this fuzzy topological structure.

این پاسخ قوی است.

26. UMAP چه زمانی عالی است؟

مخصوصاً برای:

Embeddings

مثلاً:

BERT embeddings = 768D
CNN embeddings = 2048D
ViT embeddings = 768D

برای دیدن structure:

$$768D \rightarrow 2D$$

Single-cell biology

مثل:

- scRNA-seq
 - proteomics
-

Medical imaging embeddings

مثلاً:

MRI → encoder → 512D embedding
↓
UMAP
↓
2D

می‌بینیم آیا بیماران یا phenotypes structure دارند.

Multimodal data

می‌توان embeddings مربوط به:

- image
- text
- nutrition
- behavior

را بررسی کرد.

27. مهم‌ترین Hyperparameter UMAP: `n_neighbors`

مثلاً:

`UMAP(n_neighbors=15)`

این parameter تعیین می‌کند UMAP neighborhood را در چه scale نگاه کند.

`n_neighbors` کوچک

مثلاً:

`n_neighbors=5`

تأکید زیاد روی:

Local structure

ممکن است clusterهای کوچک و tight زیادی ببینی.

n_neighbors بزرگ

مثلاً:

`n_neighbors=100`

تأکید بیشتری روی broader/global structure.

به شکل شهودی:

`n_neighbors = 5`

"پنج نفر اطراف هر فرد را جدی بگیر"

`n_neighbors = 100`

"ساختار بزرگ‌تر جمعیت را هم در نظر بگیر"

28. دومین Hyperparameter مهم: min_dist

مثلاً:

`min_dist=0.1`

کنترل می‌کند points در embedding نهایی چقدر اجازه دارند به هم نزدیک شوند.

کوچک

`min_dist=0.0`


clusterها compact و فشرده‌تر.



بزرگ

`min_dist=0.8`

clusterها diffuse:



یک خطر

با کاهش `min_dist` می‌توانی clusterهایی بسیار زیبا تولید کنی.

اما:

Beautiful clusters do not necessarily mean real clusters.

این جمله برای مصاحبه بسیار مهم است.

29. metric در UMAP

خیلی مهم.

Default معمولاً:

`euclidean`

ولی بسته به داده ممکن است:

- cosine
- correlation
- Manhattan

- Minkowski

مناسب‌تر باشند.

برای cosine distance، embeddings اغلب meaningful است.

مثلاً text embeddings:

$$d_{\text{cosine}} = 1 - \frac{x \cdot y}{\|x\| \|y\|}$$

30. n_components

برای visualization:

`n_components=2`

یا:

`n_components=3`

ولی اگر قرار است UMAP را برای downstream clustering استفاده کنی:

`n_components=10`

یا:

`n_components=20`

گاهی منطقی‌تر از 2D است.

31. UMAP stochastic است

PCA تقریباً deterministic است.

UMAP optimization stochastic دارد.

پس:

random_state=42

مهم است.

ممکن است دو اجرای مختلف کمی layouts متفاوت بدهند.

اما structure اصلی ideally باید نسبتاً stable باشد.

32. آیا فاصله در UMAP دقیقاً معنی دارد؟

نه.

این اشتباه رایج است.

فرض کن UMAP:

Cluster A

Cluster B

نباید بگوییم:

A دقیقاً 10 برابر از B دورتر است.

Global distances در UMAP ممکن است distort شوند.

به خصوص:

- distance between clusters
- cluster area
- density

نباید خیلی literal تفسیر شوند.

33. آیا اندازه cluster در UMAP معنی population size دارد؟

نه لزوماً.

مثلاً یک cluster بزرگ‌تر در plot لزوماً:

biological variability بیشتری دارد

یا:

samples بیشتری دارد

را ثابت نمی‌کند.

UMAP local geometry را تغییر می‌دهد.

34. Scaling برای UMAP

اگر داده numeric heterogeneous باشد:

Age: 20–80
Income: 0–1,000,000
Score: 0–1

باید معمولاً standardize شود.

ولی اگر embeddings داری، گاهی:

`normalize(X)`

و cosine distance منطقی‌تر است.

35. چگونه UMAP را Hyperparameter Tune کنیم؟

این کار خطرناک است اگر فقط به چشم نگاه کنیم.

مثلاً grid:

```
n_neighbors:  
5, 10, 15, 30, 50, 100  
  
min_dist:  
0.0, 0.1, 0.3, 0.5, 0.8  
  
metric:  
euclidean / cosine
```

بعد باید:

1. neighborhood preservation
2. stability
3. downstream utility

را بررسی کنیم.

نه صرفاً:

کدام plot خوشگل تر است؟

36. معیار ارزیابی UMAP چیست؟

UMAP مانند PCA چیزی به نام explained variance ندارد.

این نکته خیلی مهم است.

Trustworthiness

یکی از بهترین metrics.

می‌سنجد:

آیا points که در embedding همسایه شده‌اند، در فضای اصلی نیز واقعاً همسایه بوده‌اند؟

مقدار تقریباً:

$$0 \rightarrow 1$$

است.

هرچه نزدیک‌تر به 1:

بهتر.

در sklearn حتی تابع:

```
from sklearn.manifold import trustworthiness
```

وجود دارد.

Neighborhood Preservation

مثلاً بررسی کنیم چند درصد k-nearest-neighbor ها بعد از projection حفظ شده‌اند.

Continuity

تقریباً complement trustworthiness است:

neighborهایی که در original space وجود داشتند، آیا بعد از embedding از دست رفته‌اند؟

Stability

UMAP را با seedهای مختلف اجرا کن.

اگر هر بار structure کاملاً متفاوت باشد:

نتیجه مشکوک است. 🚨

Downstream performance

مثلاً:

UMAP 10D → DBSCAN → Silhouette 0.58

PCA 20D → DBSCAN → Silhouette 0.64

در این صورت PCA representation شاید برای clustering بهتر باشد.

37. آیا UMAP برای clustering مناسب است؟

جواب:

Sometimes, but with caution.

یک pipeline رایج:

```
X
↓
UMAP 2D
↓
DBSCAN
```

وجود دارد ولی UMAP 2D ممکن است density را distort کند.

من برای کار علمی معمولاً ترجیح می‌دهم چیزی مثل:

```
X
↓
PCA 50D
↓
DBSCAN
```

یا:

```
X
↓
PCA
↓
UMAP 10D
↓
DBSCAN
```

و UMAP 2D صرفاً برای visualization.

38. محدودیت‌های UMAP

- stochastic
 - parameter sensitive
 - global distances می‌توانند misleading باشند
 - apparent clusters ممکن است artifact باشند
 - interpretability axes پایین است
 - component 1 و component 2 مثل PCA معنی فیزیکی ندارند
 - انتخاب metric مهم است
-

39. پاسخ مصاحبه‌ای UMAP

UMAP is a nonlinear manifold-learning and dimensionality-reduction method that constructs a nearest-neighbor graph in the original high-dimensional space and optimizes a lower-dimensional representation that preserves local neighborhood structure.

40. DBSCAN چیست؟

Density-Based Spatial Clustering of Applications with Noise

یک الگوریتم:

Density-based clustering

است.

ایده:

Cluster جایی است که نقاط با density بالا وجود دارند و مناطق sparse cluster را از هم جدا می‌کنند.

41. چرا DBSCAN جالب است؟

برخلاف K-Means:

نیازی نیست بگوییم:

$K = 3$


DBSCAN خودش بر اساس density cluster را پیدا می‌کند.

همچنین:

Noise/outlier را به صورت explicit تشخیص می‌دهد.

42. مثال شهودی

فرض کن:



DBSCAN:

● = Cluster 1
▲ = Cluster 2
x = Noise

43. دو Hyperparameter حیاتی DBSCAN

1. eps

ϵ

شعاع neighborhood.

مثلاً اگر:

$eps=0.5$

دو point با distance کمتر از 0.5 neighbor محسوب می‌شوند.

2. min_samples

حداقل تعداد samples در eps-neighborhood تا آن ناحیه dense محسوب شود.

مثلاً:

```
DBSCAN(  
    eps=0.5,  
    min_samples=5  
)
```

نکته sklearn:

خود point نیز در min_samples شمرده می‌شود.

44. سه نوع Point در DBSCAN

این را باید کامل بلد باشی.

Core Point

اگر:

$$|N_{\epsilon}(p)| \geq MinPts$$

باشد.

یعنی تعداد نقاط neighborhood کافی است.

Border Point

خودش core نیست، اما در neighborhood یک core point قرار دارد.

Noise Point

نه core است و نه به یک dense region متصل است.

در sklearn:

label = -1

45. الگوریتم DBSCAN

فرض کن یک point انتخاب کردیم.

حالت 1

اگر core نیست:

فعلاً noise/border محسوب می‌شود.

حالت 2

اگر core است:

یک cluster جدید شروع می‌شود.

سپس تمام neighborهایش را پیدا می‌کنیم.

اگر neighbor نیز core باشد:

neighborهای او را هم اضافه می‌کنیم.

این expansion ادامه پیدا می‌کند.

بنابراین cluster می‌تواند shape خیلی پیچیده داشته باشد.

46. Density Reachability

اگر:

$A \rightarrow B \rightarrow C \rightarrow D$

و این chain از core points عبور کند، D می‌تواند density-reachable از A باشد حتی اگر مستقیم neighbor نباشند.

همین ویژگی باعث می‌شود DBSCAN clusterهای arbitrary-shaped پیدا کند.

47. چرا DBSCAN از K-Means بهتر می‌تواند باشد؟

فرض کن clusterها:



•••••

▲
▲
▲▲
▲
▲

K-Means با centroid کار می‌کند و shape های roughly spherical را ترجیح می‌دهد.

DBSCAN:

arbitrary shape

را می‌تواند تشخیص دهد.

48. مثال کلاسیک: Two Moons

•••••
•
•
▲
▲
▲▲▲▲

K-Means احتمالاً اشتباه تقسیم می‌کند.

DBSCAN معمولاً بسیار بهتر است.

49. eps اگر خیلی کوچک باشد چه می‌شود؟

مثلاً:

$$\epsilon = 0.05$$

نتیجه:

```
cluster 1  
cluster 2  
cluster 3  
cluster 4  
...  
lots of noise
```

یعنی over-fragmentation.

50. eps اگر خیلی بزرگ باشد؟

مثلاً:

$$eps=10$$

ممکن است:

everything → one giant cluster

51. min_samples کوچک چه می‌کند؟

مثلاً:

min_samples = 2

algorithm خیلی permissive می‌شود.

حتی densityهای ضعیف ممکن است cluster شوند.

Noise کمتر.

ولی false cluster بیشتر.

52. min_samples بزرگ؟

مثلاً:

min_samples = 30

density requirement شدیدتر.

نتیجه:

- clusterهای robustتر

- noise بیشتر

53. چگونه eps را انتخاب کنیم؟

یکی از سؤال‌های خیلی خوب مصاحبه.

روش معروف:

k-distance plot


اگر:

`min_samples = 5`

برای هر sample فاصله تا پنجمین nearest neighbor را پیدا می‌کنیم.

بعد distance ها را sort می‌کنیم.

مثلاً:



مقدار اطراف elbow می‌تواند candidate خوبی برای eps باشد.

54. min_samples را چطور انتخاب کنیم؟

rule مطلق وجود ندارد.

یک heuristic رایج:

$$\min_samples \approx 2D$$

که D تعداد dimensions است.

ولی این **قانون علمی قطعی نیست**.

مثلاً اگر:

$$D=5$$

ممکن است:

`min_samples=10`

شروع مناسبی باشد.

ولی باید sensitivity analysis انجام شود.

55. چرا High-dimensional data برای DBSCAN بد است؟

به دلیل:

Curse of Dimensionality

در dimensions بالا فاصله‌ها concentration پیدا می‌کنند.

یعنی difference بین:

- nearest neighbor
- farthest neighbor

کم می‌شود.

پس مفهوم density خراب می‌شود.

مثلاً:

768D embedding

را مستقیم دادن به DBSCAN اغلب ایده خوبی نیست.

بهتر:

768D

↓

PCA → 20-50D

↓

DBSCAN

56. Distance Metric در DBSCAN

خیلی مهم است.

Default معمولاً Euclidean.

ولی می‌توان:

- Manhattan
- Minkowski
- cosine
- precomputed

داشت.

Metric باید متناسب با داده باشد.

برای embeddings:

Cosine similarity/distance می‌تواند معنی‌دارتر باشد.

57. بزرگ‌ترین مشکل DBSCAN

Different Density Clusters

مثلاً:

●●●●●●●●

▲ ▲
 ▲
▲ ▲

cluster اول dense است.

cluster دوم sparse.

یک eps:

- برای اول خوب است

- برای دوم خیلی کوچک است

یا برعکس.

DBSCAN در variable-density data مشکل دارد.

اینجا روش‌هایی مثل:

HDBSCAN

معمولاً بهتر هستند.

58. چگونه بفهمیم DBSCAN خوب عمل کرده؟

چند metric.

Silhouette Score

برای هر point:

- a = average distance to own cluster
- b = average distance to nearest other cluster

$$s = \frac{b - a}{\max(a, b)}$$

range:

$$-1 \leq s \leq 1$$

نزدیک +1

عالی.

نزدیک 0

cluster overlap.

منفی

sample احتمالاً به cluster اشتباه assigned شده.

مشکل Silhouette برای DBSCAN

DBSCAN noise دارد.

بنابراین ممکن است لازم باشد silhouette را:

- روی non-noise points

- با توضیح مناسب

محاسبه کنی.

ولی نباید فقط Silhouette را optimize کنی.

ممکن است الگوریتم نصف داده را noise کند و silhouette مصنوعی بالا برود.

59. Davies–Bouldin Index

بررسی می‌کند:

- intra-cluster compactness
- inter-cluster separation

کمتر:

بهتر.

60. Calinski–Harabasz Score

نسبت:

$$\frac{\text{between-cluster dispersion}}{\text{within-cluster dispersion}}$$

بالاتر:

معمولاً بهتر.

61. DBCV

برای density-based clustering metric مهم‌تری وجود دارد:

Density-Based Clustering Validation

یا:

DBCV

که برای clusterهایی با شکل arbitrary و density-based مناسب‌تر از silhouette است.

مقدار بالاتر معمولاً بهتر.

62. Noise Fraction

خودش metric رسمی کافی نیست ولی باید بررسی شود.

مثلاً:

```
eps = 0.2  
Clusters = 5  
Noise = 70%
```

احتمالاً configuration مناسبی نیست مگر اینکه مسئله واقعاً 70% anomaly داشته باشد.

63. Stability Analysis

مثلاً:

```
eps = 0.40 → 4 clusters  
eps = 0.42 → 4 clusters  
eps = 0.44 → 4 clusters  
eps = 0.46 → 4 clusters
```

نتیجه stable.

ولی اگر:

0.40 → 8 clusters
0.41 → 3 clusters
0.42 → 1 cluster

configuration بسیار حساس است.

64. اگر Ground Truth داشته باشیم

اگر labels واقعی داریم ولی clustering را unsupervised اجرا کرده‌ایم، می‌توانیم از external metrics استفاده کنیم:

- Adjusted Rand Index — ARI
- Normalized Mutual Information — NMI
- Adjusted Mutual Information — AMI

ولی در pure clustering معمولاً label واقعی نداریم.

65. DBSCAN برای چه مسئله‌هایی مناسب است؟

مناسب وقتی:

- K را نمی‌دانی
 - noise/outlier داری
 - arbitrary cluster shape داری
 - density structure meaningful است
 - dimensions خیلی زیاد نیست
-

66. DBSCAN چه زمانی مناسب نیست؟

وقتی:

- density بسیار متفاوت اند
 - dataset بسیار high-dimensional است
 - clusterها خیلی overlap دارند
 - probability membership می‌خواهی
-

67. پاسخ مصاحبه‌ای DBSCAN

DBSCAN is a density-based clustering algorithm that groups density-connected points into clusters while labeling points in sparse regions as noise. Its main hyperparameters are epsilon, which defines the neighborhood radius, and min_samples, which defines the minimum local density required for core points.

68. GMM چیست؟

Gaussian Mixture Model

یک:

probabilistic generative model

است.

فرض می‌کند:

Data از ترکیب چند Gaussian distribution تولید شده است.

مثلاً:



69. فرمول GMM

$$p(x)=\sum_{k=1}^K \pi_k N(x\mid \mu_k, \Sigma_k)$$

که:

K

تعداد Gaussian components.

π_k

mixing coefficient.

شرط:

$$\sum_k \pi_k=1$$

μ_k

mean cluster k .

Σ_k

covariance matrix.

70. مثال بسیار خوب

فرض کن height جمعیتی داریم.


Population اول:

$$\mu = 165$$

Population دوم:

$$\mu = 180$$

Distribution:



GMM می‌گوید:

این distribution کل، mixture دو Gaussian است.

71. تفاوت K-Means و GMM

این را باید خیلی خوب بلد باشی.

K-Means:

هر sample دقیقاً در یک cluster است.

مثلاً:

$x \rightarrow \text{Cluster 2}$

این:

Hard assignment

است.

GMM:

x:

Cluster 1 = 0.10

Cluster 2 = 0.72

Cluster 3 = 0.18

این:

Soft / probabilistic assignment

است.

72. Responsibility چیست؟

احتمال posterior اینکه x_i sample متعلق به k component باشد:

$$\gamma_{ik} = P(z_i = k \vee x_i)$$

مثلاً:

Patient 27

G1 = 0.02

G2 = 0.85

G3 = 0.13

این uncertainty بسیار useful است.

73. مثال پزشکی

فرض کن patient embeddings داریم.

ممکن است سه phenotype latent وجود داشته باشند.

یک patient:

Phenotype A = 0.76
Phenotype B = 0.21
Phenotype C = 0.03

GMM فقط cluster نمی‌دهد.

بلکه confidence/membership probability هم می‌دهد.

74. GMM چگونه fit می‌شود؟

معمولاً با:

EM Algorithm

= Expectation Maximization.

75. E-step

با parameters فعلی محاسبه می‌کنیم:

$$\gamma_{ik} = P(z_i = k \mid x_i)$$

مثلاً:

sample 1 → [0.9, 0.1]
sample 2 → [0.6, 0.4]
sample 3 → [0.1, 0.9]

76. M-step

با responsibility های جدید parameters را update می‌کنیم.

اگر:

$$N_k = \sum_i y_{ik}$$

آنگاه:

$$\mu_k = \frac{1}{N_k} \sum_i y_{ik} x_i$$

و:

$$\pi_k = \frac{N_k}{N}$$

و covariance نیز دوباره estimate می‌شود.

بعد:

E-step
↓
M-step
↓
E-step
↓
M-step
↓
...

تا convergence.

77. چرا EM لازم است؟

چون ما نمی‌دانیم:

- Gaussian ها کجا هستند

- هر sample به کدام Gaussian تعلق دارد

این latent variable problem است.

EM به صورت iterative:

1. membership ها را estimate می‌کند.

2. parameters را estimate می‌کند.

78. Covariance در GMM چرا مهم است؟

فرض کن cluster:

```
****
*****
*****
```

یا:

```
*
**
***
***
**
```

باشد.

با Gaussian، covariance matrix می‌تواند elliptical باشد.

79. covariance_type

در sklearn چهار حالت مهم داریم.

spherical

هر cluster:

$$\Sigma_k = \sigma_k^2 I$$

یعنی دایره/کره.

ساده‌ترین.

diag

هر dimension variance خودش را دارد، ولی covariance بین dimensions صفر فرض می‌شود.

tied

تمام components یک covariance matrix مشترک دارند.

full

هر component covariance matrix کامل خودش را دارد.

انعطاف پذیرترین.

ولی parameters بیشتری دارد.

80. مثال هندسی

spherical



full



full می‌تواند orientation و correlation را مدل کند.

81. Hyperparameter اصلی `n_components` GMM:

مثلاً:

```
GaussianMixture(n_components=3)
```

برخلاف DBSCAN:

باید تعداد components را تعیین کنیم.

ولی چطور؟

82. چرا نباید صرفاً likelihood را برای K انتخاب کنیم؟

با افزایش number of components معمولاً training likelihood بالا می‌رود.

مثلاً:

```
K=2    likelihood = 100  
K=5    likelihood = 150  
K=20   likelihood = 300
```

ولی K=20 شاید overfit باشد.

پس نیاز به complexity penalty داریم.

83. AIC

Akaike Information Criterion

$$AIC = -2 \log L + 2p$$

که:

- L = likelihood

- p = number of model parameters

کمتر:

بهرتر.

84. BIC

Bayesian Information Criterion

$$BIC = -2 \log L + p \log n$$

کمتر:

بهرتر.

BIC نسبت به AIC معمولاً penalty بیشتری برای complexity می‌دهد، مخصوصاً وقتی n بزرگ باشد.

85. مثال انتخاب K

K	BIC
1	8250
2	7100
3	6530
4	6280
5	6350
6	6430

انتخاب:

86. BIC یا AIC؟

در mixture model selection معمولاً:

BIC بسیار رایج است.

اگر هدف model selection باشد:

Lower BIC indicates a better trade-off between model fit and complexity.

AIC معمولاً کمتر سختگیر است و ممکن است components بیشتری انتخاب کند.

87. Hyperparameter های مهم دیگر GMM

covariance_type

full / tied / diag / spherical

n_init

چند بار model با initialization متفاوت fit شود.

مثلاً:

`n_init=10`

و بهترین solution نگه داشته شود.

چون EM ممکن است در local optimum گیر کند.

max_iter

حداکثر iterations.

tol

convergence tolerance.

reg_covar

regularization به covariance matrix اضافه می‌کند.

مثلاً:

```
reg_covar=1e-6
```

برای جلوگیری از numerical singularity.

88. Initialization GMM

خیلی مهم است.

می‌توان از K-Means برای initialization استفاده کرد.

اگر initialization بد باشد:

EM ممکن است به local optimum ضعیف برسد.

پس:

```
n_init > 1
```

اغلب خوب است.

89. Scaling برای GMM

خیلی مهم.

چون covariance و Gaussian density شدیداً به scale وابسته‌اند.

پس معمولاً:

StandardScaler

↓

GMM

90. چگونه GMM را ارزیابی کنیم؟

BIC

بسیار مهم برای number of components.

AIC

مدل fit در برابر complexity.

Log-likelihood

روی validation/test data.

مثلاً:

$$\frac{1}{n} \sum_i \log p(x_i)$$

بالا تر:

بهتر.

ولی روی training alone برای مقایسه K کافی نیست.

Convergence

باید بررسی شود model واقعاً converge کرده یا نه.

Posterior probabilities

اگر بیشتر samples:

[0.34, 0.33, 0.33]

دارند، clusters خیلی ambiguous هستند.

ولی اگر:

[0.98, 0.01, 0.01]

assignment بسیار confident است.

91. Entropy of Assignment

می‌توان uncertainty membership را با entropy سنجید:

$$H_i = - \sum_k p_{ik} \log p_{ik}$$

entropy کم:

membership confident.

entropy بالا:

ambiguous.

92. Silhouette برای GMM؟

می‌شود hard labels:

```
gmm.predict(X)
```

را گرفت و silhouette حساب کرد.

ولی باید بدانیم:

GMM fundamentally density/probability model است.

BIC / held-out likelihood برای naturalتر هستند.

93. External labels

اگر labels واقعی داریم:

- ARI
- NMI
- AMI

قابل استفاده‌اند.

94. GMM چه زمانی مناسب است؟

وقتی:

- clusterها roughly Gaussian/elliptical باشند
 - overlap داشته باشند
 - soft assignment مهم باشد
 - uncertainty مهم باشد
 - density modeling می‌خواهیم
-

95. GMM چه زمانی بد است؟

اگر clusterها:

C-shaped
spiral
ring
moon

باشند.

یک Gaussian representation طبیعی نیست.

مثلاً:

ooooo
o
o
ooooo

را GMM شاید مجبور شود با چند Gaussian تکه‌تکه کند.

DBSCAN مناسب‌تر است.

96. یک مثال قوی برای فهم تفاوت GMM و DBSCAN

فرض کن داده:

```

      *****
*****
      *****

```

+++++

+++++

دو cluster elliptical که overlap کمی دارند.

GMM:

✓ بسیار مناسب.

DBSCAN:

ممکن است مناسب باشد، ولی probability membership نمی‌دهد.

اما اگر:

DBSCAN:

مناسب. 

GMM:

Gaussian assumption ضعيف. ❌

بخش پنجم — نکته بسیار مهم: معیار ارزیابی این چهار روش یکسان نیست

چون:

PCA, UMAP
=
Representation methods

DBSCAN, GMM
=
Clustering methods

نباید metric ها را قاطی کنیم.

97. معیارهای PCA

Metric	معنی
Explained Variance Ratio	مقدار variance حفظ شده
Cumulative Explained Variance	variance مجموع component ها
Reconstruction Error	اطلاعات از دست رفته
Downstream Performance	usefulness representation
Stability	پایداری components

98. معیارهای UMAP

Metric	معنی
Trustworthiness	آیا همسایه های ساختگی ایجاد شده اند؟
Continuity	آیا همسایه های اصلی از دست رفته اند؟
k-NN preservation	میزان حفظ همسایگی

Metric	معنی
Stability	robustness نسبت به seed/hyperparameters
Downstream Performance	usefulness embedding

نکته:

UMAP explained variance ندارد.

99. معیارهای DBSCAN

Metric	هدف
Silhouette	separation/compactness
Davies-Bouldin	separation
Calinski-Harabasz	between/within dispersion
DBCV	density-clustering validation
Noise fraction	sanity check
Stability	robustness
ARI/NMI	اگر ground truth باشد

100. معیارهای GMM

Metric	هدف
BIC	model fit + complexity
AIC	model fit + complexity
Log-likelihood	density fit

Metric	هدف
Held-out likelihood	generalization
Membership entropy	uncertainty
Silhouette	optional hard-label check
ARI/NMI	ground truth available

بخش ششم — Hyperparameter Tuning عملی

PCA

اصلی:

`n_components`

روش:

Explained variance
+
Scree plot
+
Downstream validation

UMAP

اصلی:

`n_neighbors`
`min_dist`
`metric`
`n_components`

روش:

مثلاً:

`n_neighbors:`
5, 15, 30, 50, 100

`min_dist:`
0.0, 0.1, 0.3, 0.5

metric:
euclidean / cosine

بعد:

Trustworthiness
+
Stability
+
Domain interpretation
+
Downstream performance

DBSCAN

اصلي:

eps
min_samples
metric

روشن:

Scaling
↓
choose min_samples
↓
k-distance plot
↓
candidate eps
↓
sensitivity analysis
↓
DBCV/Silhouette + noise fraction

GMM

اصلي:

n_components
covariance_type
n_init
reg_covar

مثلاً:

$K = 1..10$

covariance_type:
full
diag
tied
spherical

و:

BIC / AIC
+
held-out likelihood
+
stability

بخش هفتم — یک مثال جامع از هر چهار روش

فرض کن:

Multimodal Food Dataset

برای هر meal داریم:

Image embedding = 768 features
Nutrition = 20 features
Context = 10 features

Total $\approx$ 798 dimensions

مرحله 1

Preprocessing:

missing values
scaling
normalization

PCA — مرحله 2

مثلاً:

798D
↓
PCA
↓
50D

و 50 components:

94 %


variance را حفظ می‌کنند.

مرحله 3 — UMAP

برای visualization:

50D
↓
UMAP
↓
2D

می بینیم:



ممکن است latent structure وجود داشته باشد.

مرحله 4a — DBSCAN

روی مثلاً PCA representation:

PCA 50D
↓
DBSCAN

می بینیم:

Cluster 0 → desserts
Cluster 1 → salads
Cluster 2 → meat-heavy meals
Noise → unusual meals

مرحله 4b — GMM

همین data:

PCA 50D
↓
GMM

مثلاً BIC می گوید:

$$K=4$$

بهترین است.

یک meal:

healthy plant-based	= 0.64
mixed meal	= 0.31
dessert	= 0.03
meat-heavy	= 0.02

GMM نشان می‌دهد boundary نرم هستند.

بخش هشتم — PCA یا UMAP؟

این سؤال مصاحبه‌ای محتمل است.

PCA انتخاب کن اگر:

- interpretability مهم است
 - linear structure داری
 - سرعت مهم است
 - reproducibility مهم است
 - preprocessing می‌خواهی
 - explained variance لازم داری
-

UMAP انتخاب کن اگر:

- nonlinear structure محتمل است
- visualization مهم است
- embeddings داری

- local neighborhoods مهم هستند

- manifold structure می‌خواهی

101. چرا PCA را قبل از UMAP استفاده کنیم؟

مثلاً:

$$2048 D \rightarrow PCA_{50} \rightarrow UMAP_2$$

مزایا:

- noise reduction
- computation کمتر
- nearest-neighbor search بهتر
- UMAP سریع‌تر
- numerical stability بهتر

این pipeline بسیار رایج و defensible است.

102. ولی PCA ممکن است information مهم حذف کند؟

بله.

اگر cluster-separating information در low-variance dimensions باشد.

پس باید validate شود.

بخش نهم — DBSCAN یا GMM؟

DBSCAN:

وقتی:

- K نامشخص

- noise مهم

- irregular cluster shapes
 - density-based structure
-

GMM:

وقتی:

- K قابل تخمین

- Gaussian/elliptical clusters
- overlap
- probabilistic assignment

- uncertainty مهم

103. آیا DBSCAN probability می‌دهد؟

نه به صورت استاندارد.

Label می‌دهد:

0
1
2
-1

ولی GMM:

[0.1, 0.7, 0.2]

می‌دهد.

104. آیا GMM Noise Class دارد؟

نه به شکل native DBSCAN.

هر point باید تحت mixture model probability داشته باشد.

می‌توان low likelihood points را anomaly دانست، ولی concept آن با DBSCAN noise متفاوت است.

105. K-Means کجای این داستان است؟

برای فهم مصاحبه‌ای:

K-Means را می‌توان تقریباً مثل یک مدل clustering ساده دید که مناسب clusterهای:

- spherical
- similar size
- similar variance

است.

GMM را می‌توان extension بسیار انعطاف‌پذیرتری تصور کرد که:

- covariance
- ellipse
- soft membership

دارد.

البته از نظر ریاضی GMM فقط «K-Means بهتر» نیست؛ GMM یک probabilistic density model است.

بخش دهم — مهم‌ترین خطاهای مصاحبه‌ای

این‌ها را نگو:

PCA یک clustering method است. ❌

UMAP اگر clusterهای قشنگ نشان داد یعنی clusterهای واقعی وجود دارند. ❌

PCA 95% variance یعنی 95% accuracy. ❌

DBSCAN نیازی به tuning ندارد چون K نمی‌خواهد. ❌

GMM حتماً cluster واقعی پیدا می‌کند. ❌

Silhouette تنها معیار کافی clustering است. ❌

UMAP axes معنای مستقیمی مثل PCA دارند. ❌

Euclidean distance همیشه بهترین metric است. ❌

106. نکته درباره Data Leakage

اگر PCA را در یک supervised pipeline استفاده می‌کنی:

غلط:

```
PCA on entire dataset
↓
train/test split
```

چون test information وارد PCA شده.

صحیح:

```
train/test split
↓
fit scaler on train
↓
fit PCA on train
↓
transform train/test
```

بهترین حالت:

```
Pipeline([
    ("scaler", StandardScaler()),
    ("pca", PCA(...)),
    ("model", ...)
])
```

در cross-validation.

برای pure exploratory unsupervised analysis مسئله متفاوت است، ولی در predictive evaluation leakage باید جدی گرفته شود.

107. آیا قبل از DBSCAN و GMM Scaling لازم است؟

تقریباً همیشه اگر feature scales متفاوت باشد:

بله. 

مثلاً:

```
Age = 50
Income = 100000
Risk = 0.7
```

در Euclidean space:

Income dominate می‌کند.

108. آیا PCA خودش scaling می‌کند؟

PCA در sklearn:

centering انجام می‌دهد. ✓

اما:

standardization انجام نمی‌دهد. ✗

یعنی باید اگر لازم است خودت:

StandardScaler
↓
PCA

انجام دهی.

بخش یازدهم — Decision Guide

اگر از من بپرسی:

«500-dimensional embeddings دارم، چکار کنم؟»

اغلب:

Normalize/Scale
↓
PCA ~ 30-100D
↓
UMAP 2D for visualization

اگر clustering لازم باشد:

PCA 30-100D
↓
DBSCAN/GMM

و clustering را validate کن.

«تعداد cluster را نمی‌دانم و noise زیاد است.»

DBSCAN candidate قوی.

«سه population overlapping دارم و uncertainty مهم است.»

GMM candidate قوی.

«featureهای strongly correlated و high-dimensional دارم.»

PCA.

«می‌خواهم structure یک 768D embedding را ببینم.»

UMAP.

بخش دوازدهم — جدول نهایی مقایسه کامل

ویژگی	PCA	UMAP	DBSCAN	GMM
نام کامل	Principal Component Analysis	Uniform Manifold Approximation and Projection	Density-Based Spatial Clustering of Applications with Noise	Gaussian Mixture Model
نوع روش	Dimensionality Reduction	Dimensionality Reduction	Clustering	Clustering / Density Modeling
Supervision	Unsupervised	Unsupervised	Unsupervised	Unsupervised
Linear/Nonlinear	Linear	Nonlinear	Nonlinear clustering	Probabilistic
هدف اصلی	کاهش ابعاد با حفظ variance	حفظ neighborhood/manifold structure	یافتن dense clusters	مدل‌سازی mixture توزیع‌های Gaussian

ویژگی	PCA	UMAP	DBSCAN	GMM
خروجی	Principal Components	Low-dimensional embedding	Cluster label	Probability + label
تعداد Cluster لازم؟	N/A	N/A	خیر	بله
Noise detection	خیر	خیر	بله	مستقیم خیر
Soft membership	خیر	خیر	خیر	بله
Cluster shape	N/A	N/A	Arbitrary	Gaussian/Elliptical
overlap مناسب برای	N/A	N/A	محدود	بسیار مناسب
irregular مناسب برای shape	N/A	N/A	بسیار مناسب	ضعیف
high-dimensional مناسب	بله	بله	مستقیم نه چندان	با احتیاط
Visualization	متوسط	عالی	نه هدف اصلی	نه هدف اصلی
Interpretability	نسبتاً بالا	پایین تر	متوسط	نسبتاً بالا
Stochastic	تقریباً خیر	بله	معمولاً خیر	initialization-dependent
Scaling حساس به	بله	بله	خیلی زیاد	خیلی زیاد
Outlier حساس به	بله	می تواند باشد	خودش outlier پیدا می کند	بله
فرض اصلی	variance structure خطی	manifold/local neighborhood	density-based structure	Gaussian mixture
اصلی Hyperparameter	n_components	n_neighbors, min_dist	eps, min_samples	n_components, covariance_type
Tune روش	Explained variance / CV	Trustworthiness + stability	k-distance + validation	BIC/AIC
اصلی Metric	Explained variance	Trustworthiness	DBCV / Silhouette	BIC / likelihood

ویژگی	PCA	UMAP	DBSCAN	GMM
معیار اضافی	Reconstruction error	Neighbor preservation	DB / CH / stability	AIC / entropy
مشکل اصلی	linearity	distortion/artifacts	varying density	Gaussian assumption
بهترین کاربرد	Compression/preprocessing	Visualization/manifold	arbitrary clusters + noise	overlapping probabilistic clusters

جدول خیلی مهم: اثر Hyperparameter ها

Method	Parameter	اگر کم شود	اگر زیاد شود
PCA	n_components	compression بیشتر،	information بیشتر،
		information loss بیشتر	compression کمتر
UMAP	n_neighbors	local structure بیشتر	global structure بیشتر
UMAP	min_dist	clusters فشرده‌تر	embedding پراکنده‌تر
DBSCAN	eps	noise/fragmentation بیشتر	clusters merge می‌شوند
DBSCAN	min_samples	clustering permissive تر	density requirement سخت‌تر
GMM	n_components	underfitting محتمل	overfitting محتمل
GMM	reg_covar	flexibility بیشتر ولی	covariance پایدارتر
		instability محتمل	
GMM	n_init	local optimum risk بالاتر	robustness بیشتر ولی
			computation بیشتر

جدول انتخاب سریع روش

انتخاب مناسب	وضعیت
PCA	Feature های زیاد و correlated
UMAP	Nonlinear high-dimensional visualization
UMAP	Embedding visualization
PCA	کاهش noise قبل clustering
DBSCAN	تعداد cluster نامعلوم
DBSCAN	Noise/outlier زیاد
DBSCAN	Cluster های غیرکروی
GMM	Cluster های overlapping
GMM	Membership probability لازم
GMM	Cluster های elliptical
GMM	Model-based density estimation

چهار جمله‌ای که باید کاملاً حفظ باشی

PCA

PCA finds orthogonal linear directions that maximize variance and uses the leading components to represent high-dimensional data with fewer dimensions.

UMAP

UMAP is a nonlinear manifold-learning method that constructs a nearest-neighbor graph and produces a lower-dimensional embedding designed to preserve local neighborhood structure.


DBSCAN

DBSCAN identifies clusters as density-connected regions, does not require specifying the number of clusters in advance, and explicitly labels sparse observations as noise.

GMM

GMM models the data as a probabilistic mixture of Gaussian components and provides soft posterior probabilities of membership for each observation.

و مهم‌ترین تصویر ذهنی این چهار روش



اگر برای مصاحبه واقعاً می‌خواهی فول شوی، قدم بعدی مهم‌تر از توضیحات تئوری است: باید برای هر چهار روش یک **dataset کوچک را عدد به عدد جلو ببریم**؛ مثلاً برای PCA واقعاً covariance/eigenvector را حساب کنیم، برای DBSCAN با ۸-۱۰ نقطه دستی مشخص کنیم کدام Core/Border/Noise است، و برای GMM یک iteration از E-step و M-step را انجام دهیم. آن مرحله است که این مفاهیم از «بلدم تعریف کنم» تبدیل می‌شوند به «واقعاً می‌فهمم».