

# راهنمای جامع یادگیری خودنظارتی

## Self-Supervised Learning (SSL)

از شهود پایه تا چهار مثال عمیق و کاربرد در Foundation Models پزشکی

**هدف این جزوه —** بعد از مطالعه باید بتوانید دقیقاً توضیح دهید SSL چه چیزی را بدون برچسب انسانی یاد می‌گیرد، target چگونه ساخته می‌شود، pretraining و downstream task چه تفاوتی دارند، و روش‌هایی مثل SimCLR, MAE, DINO و BERT چگونه با منطق‌های متفاوت از داده supervision می‌سازند.

نسخه آموزشی فارسی | تمرکز ویژه بر Computer Vision, Medical AI و Pathology Foundation Models

## نقشه راه یادگیری

این متن طوری طراحی شده که ابتدا مفهوم را از صفر تثبیت کند، سپس چهار خانواده مهم SSL را با مثال‌های واقعی باز کند و در پایان نشان دهد این ایده‌ها در پروژه‌های پاتولوژی دیجیتال و Foundation Model چگونه به یک pipeline پژوهشی تبدیل می‌شوند.

| بخش             | سؤال اصلی                                                                   |
|-----------------|-----------------------------------------------------------------------------|
| 1. مفهوم بنیادی | Self-Supervised Learning دقیقاً چیست و supervision از کجا می‌آید؟           |
| 2. SimCLR       | چطور با دو view از یک نمونه، representation خوب یاد می‌گیریم؟               |
| 3. MAE          | چطور با پنهان کردن بخش بزرگی از ورودی، مدل را وادار به فهم ساختار می‌کنیم؟  |
| 4. DINO         | چطور Teacher و Student بدون label و حتی بدون negative pair یاد می‌گیرند؟    |
| 5. BERT/MLM     | چرا SSL محدود به تصویر نیست و در زبان چگونه کار می‌کند؟                     |
| 6. Pathology    | این ایده‌ها در Whole-Slide Image و Foundation Model چه معنایی پیدا می‌کنند؟ |
| 7. جمع‌بندی     | چطور روش‌ها را از هم تشخیص دهیم و برای هر مسئله انتخاب کنیم؟                |

## قبل از شروع: یک جمله که باید در ذهن بماند

**تعریف فشرده —** در Self-Supervised Learning، انسان label معنایی نمی‌دهد؛ مدل یک target آموزشی را از خود داده یا از تبدیل‌های داده دریافت می‌کند و با حل آن مسئله، representation عمومی و قابل انتقال یاد می‌گیرد.

بنابراین محور SSL این نیست که «مدل چه معماری‌ای دارد»، بلکه این است که «سیگنال آموزشی از کجا آمده است». یک CNN، ViT، Transformer یا حتی GNN encoder دیگر می‌تواند در یک چارچوب self-supervised آموزش ببیند؛ مشروط بر اینکه target از خود داده استخراج یا ساخته شود.

# 1. Self-Supervised Learning دقیقاً چیست؟

## 1.1 مسئله اصلی: داده زیاد است، برچسب گران است

در بسیاری از حوزه‌ها، جمع‌آوری داده خام بسیار آسان‌تر از برچسب‌گذاری آن است. بیمارستان ممکن است میلیون‌ها تصویر پزشکی داشته باشد، اما برای تبدیل هر تصویر به یک label قابل اعتماد باید متخصص زمان صرف کند. در پاتولوژی این مسئله شدیدتر است: یک Whole-Slide Image می‌تواند بسیار بزرگ باشد و تعیین ناحیه‌های تومور، subtype یا ویژگی‌های مورفولوژیک نیازمند پاتولوژیست است. در اینترنت نیز میلیاردها تصویر، متن و ویدئو وجود دارد، اما تنها بخش کوچکی annotation دقیق دارد. اگر یادگیری فقط به supervised learning وابسته باشد، بخش عظیمی از اطلاعات موجود بلااستفاده می‌ماند.

Self-Supervised Learning راهی برای استفاده از همین داده‌های بدون label است. ایده مرکزی این است که از خود ورودی یک «مسئله آموزشی» بسازیم. در supervised learning، انسان می‌گوید این تصویر گربه است و label برابر Cat می‌شود. در SSL، ممکن است از یک تصویر دو نسخه متفاوت بسازیم و به مدل بگوییم این دو باید representation مشابه داشته باشند؛ یا 75 درصد patch‌های تصویر را مخفی کنیم و از مدل بخواهیم آن‌ها را بازسازی کند. در هر دو حالت target وجود دارد، اما target توسط انسان نوشته نشده است.

## 1.2 تفاوت مهم: Label با Target یکی نیست

یکی از جاهایی که SSL گیج‌کننده می‌شود این است که می‌گوییم «بدون برچسب» ولی در همان زمان loss محاسبه می‌کنیم. برای محاسبه loss حتماً نوعی target لازم است. نکته اینجاست که target لزوماً semantic label نیست. اگر کلمه‌ای از جمله حذف شود، خود کلمه اصلی target است. اگر patch تصویر حذف شود، pixel‌ها یا featureهای patch اصلی target هستند. اگر دو augmentation از یک تصویر ساخته شوند، هویت مشترک آن دو نمونه یک رابطه مثبت ایجاد می‌کند. بنابراین SSL بدون supervision نیست؛ اما supervision به‌طور خودکار از داده تولید می‌شود.

**اصل کلیدی — Self-supervised** یعنی «supervision خودکار از ساختار داده»، نه «نبودن loss یا target».

## 1.3 هدف واقعی SSL: یادگیری Representation

در بیشتر کاربردهای مدرن، هدف اصلی SSL این نیست که pretext task را برای همیشه حل کنیم. هدف، ساختن یک encoder است که ورودی را به representation مفید تبدیل کند. Representation معمولاً یک بردار یا مجموعه‌ای از featureهاست که اطلاعات مهم ورودی را نگه می‌دارد. اگر representation خوب باشد، نمونه‌های معنایی مشابه در فضای ویژگی ساختار مناسبی پیدا می‌کنند و یک classifier ساده با تعداد کمی label نیز می‌تواند کار خوبی انجام دهد.

| Raw Data | Self-Supervised Pretraining | Encoder | Representation | Downstream Task |
|----------|-----------------------------|---------|----------------|-----------------|
|----------|-----------------------------|---------|----------------|-----------------|

نمای کلی: مسئله self-supervised وسیله است؛ representation قابل انتقال، محصول اصلی است.

مثلاً در تصاویر بافت، یک encoder خوب ممکن است بدون دریافت label سرطان، به تدریج texture، شکل هسته‌ها، تراکم سلولی، الگوی فضایی غدد و ساختارهای تکرارشونده را در featureهای خود منعکس کند. بعداً با تعداد محدودی نمونه labeled می‌توان همین encoder را برای classification یا prognosis تنظیم کرد. به همین دلیل اصطلاح representation learning تقریباً همیشه کنار SSL دیده می‌شود.

## 1.4 دو مرحله رایج: Pretraining و Downstream Adaptation

1. Pretraining: مدل روی حجم زیادی از داده‌های بدون label با یک objective خودنظارتی آموزش می‌بیند. این مرحله می‌تواند بسیار سنگین و پرهزینه باشد.
  2. Adaptation / Fine-tuning: مدل pretrained برای یک مسئله واقعی مثل diagnosis, segmentation, retrieval یا prognosis استفاده می‌شود. ممکن است کل مدل fine-tune شود، فقط چند لایه آموزش ببینند، از linear probe استفاده شود یا روش‌های parameter-efficient به کار روند.
- Linear probing یک آزمون رایج برای کیفیت representation است: encoder را freeze می‌کنیم و فقط یک classifier خطی روی featureها آموزش می‌دهیم. اگر عملکرد خوب باشد، یعنی اطلاعات مفید از قبل در representation وجود داشته است. Fine-tuning آزمون دیگری است که در آن بخشی یا همه وزن‌های encoder نیز برای task جدید تغییر می‌کنند.

## 1.5 SSL با Unsupervised و Semi-Supervised چه فرقی دارد؟

| مثال                              | سیگنال آموزشی                      | داده برچسب‌دار             | روش                 |
|-----------------------------------|------------------------------------|----------------------------|---------------------|
| تصویر $\rightarrow$ ILC / non-ILC | Label انسانی                       | لازم است                   | Supervised          |
| K-means clustering                | ساختار آماری داده                  | لازم نیست                  | Unsupervised کلاسیک |
| Mask کردن patch و بازسازی آن      | Target ساخته شده از خود داده       | لازم نیست                  | Self-Supervised     |
| labeled + 90% 10% unlabeled       | ترکیب label واقعی و unlabeled data | کم + مقدار زیاد بدون label | Semi-Supervised     |

از دیدگاه گسترده، SSL معمولاً زیرمجموعه‌ای از unsupervised representation learning در نظر گرفته می‌شود، اما در ادبیات مدرن این دو اصطلاح را جدا می‌کنند چون SSL یک objective پیش‌بینی محور یا تطبیق محور مشخص می‌سازد. Semi-supervised نیز مفهوم دیگری است: آنجا از بخشی از labelهای انسانی استفاده می‌کنیم؛ در SSL پایه، pretraining می‌تواند کاملاً بدون label انسانی باشد.

## 1.6 چهار خانواده مهم روش‌های Self-Supervised

1. Contrastive Learning: دو view مرتبط باید در فضای representation نزدیک و نمونه‌های نامرتب‌دور شوند. SimCLR و MoCo نمونه‌های کلاسیک هستند.
2. Masked Prediction / Reconstruction: بخشی از ورودی پنهان می‌شود و مدل باید محتوای از دست‌رفته را پیش‌بینی یا بازسازی کند. MAE در تصویر و BERT در زبان نمونه‌های مهم‌اند.
3. Self-Distillation: یک student از targetهای تولیدشده توسط teacher یاد می‌گیرد، در حالی که teacher نیز از خود مدل یا میانگین وزن‌های student به‌روزرسانی می‌شود. DINO نمونه شناخته‌شده است.
4. Predictive / Redundancy-Reduction Objectives: به جای negative pair می‌توان consistency، variance و decorrelation بین viewها را کنترل کرد. BYOL و VICReg نمونه‌هایی از این خانواده گسترده‌اند.

## 1.7 چرا Augmentation تا این حد مهم است؟

در روش‌هایی مثل augmentation، SimCLR فقط یک تکنیک جانبی برای افزایش داده نیست؛ بخشی از تعریف مسئله است. با انتخاب augmentation در واقع به مدل می‌گوییم چه تغییراتی باید از نظر معنایی «بی‌اهمیت» تلقی شوند. اگر از یک تصویر crop و color jitter بسازیم و هر دو را positive pair بدانیم، مدل تشویق می‌شود نسبت به این تغییرات invariant باشد. اگر augmentation نامناسب باشد، می‌توان اطلاعاتی را حذف کرد که برای task پزشکی حیاتی است. مثلاً در بعضی کاربردهای pathology، تغییرات رنگی شدید ممکن است سیگنال مرتبط با staining را از بین ببرد. بنابراین طراحی augmentation یک فرض علمی درباره invarianceهای مسئله است.

## 1.8 خطر Representation Collapse چیست؟

اگر objective بد طراحی شود، مدل ممکن است برای همه ورودی‌ها تقریباً یک representation یکسان تولید کند. در این حالت loss ممکن است به شکل فریبنده‌ای ساده شود، اما featureها هیچ اطلاعاتی ندارند. به این پدیده representation collapse می‌گویند. روش‌های مختلف راه‌های متفاوتی برای جلوگیری از آن دارند: contrastive learning از negative samples استفاده می‌کند؛ DINO از centering، teacher-student، sharpening و VICReg روی variance و covariance constraint می‌گذارد. فهم collapse مهم است چون نشان می‌دهد «صرفاً یکسان کردن خروجی دو view» کافی نیست.

## 1.9 SSL چه چیزهایی را تضمین نمی‌کند؟

SSL معجزه نیست. اول، pretraining ممکن است shortcut یاد بگیرد؛ یعنی به جای مفهوم زیستی، artifact اسکنر یا رنگ‌آمیزی را استفاده کند. دوم، representation خوب برای یک downstream task لزوماً برای task دیگر بهترین نیست. سوم، pretraining بزرگ می‌تواند به compute و حافظه زیاد نیاز داشته باشد. چهارم، اگر داده pretraining با population هدف متفاوت باشد، domain shift باقی می‌ماند. پنجم، در پزشکی باید external validation،

calibration و بررسی bias همچنان انجام شود. SSL فقط نیاز به label را کاهش می‌دهد؛ الزامات ارزیابی بالینی را حذف نمی‌کند.

## 1.10 چرا SSL برای Foundation Models حیاتی است؟

Foundation model قرار است روی داده گسترده pretrain شود و سپس به چندین task منتقل شود. برچسب‌گذاری کل آن داده در مقیاس میلیون‌ها نمونه عملی نیست. به همین دلیل بسیاری از foundation modelها با objectiveهای self-supervised، weakly supervised یا ترکیبی ساخته می‌شوند. مدل ابتدا ساختار عمومی دامنه را می‌آموزد و بعد با fine-tuning، linear probing، adapters یا روش‌های دیگر برای taskهای خاص سازگار می‌شود. در digital pathology، این الگو بسیار طبیعی است: میلیون‌ها tile از WSI در دسترس‌اند، اما annotation تخصصی محدود است.

**اگر فقط یک تصویر ذهنی نگه دارید — SSL یعنی «ساختن تمرین از خود داده» تا encoder قبل از دیدن task نهایی، زبان آماری و ساختاری آن داده را یاد بگیرد.**

## 2. مثال اول: Contrastive Learning با SimCLR

SimCLR یکی از بهترین مثال‌ها برای فهم شهودی *contrastive self-supervised learning* است. ایده آن این است که مدل باید تشخیص دهد دو مشاهده متفاوت می‌توانند نماینده یک محتوای واحد باشند. برای این کار به *label* کلاس نیاز نداریم؛ کافی است بدانیم دو *view* از یک تصویر اصلی ساخته شده‌اند.

### 2.1 ساخت Positive Pair

یک تصویر *x* را انتخاب می‌کنیم و دو *augmentation* تصادفی مستقل روی آن اعمال می‌کنیم. مثلاً، *crop*، *resize*، *flip*، *color jitter* یا *blur*. خروجی دو تصویر *x1* و *x2* است. چون هر دو از یک نمونه آمده‌اند، آن‌ها *positive pair* محسوب می‌شوند. تصاویر دیگر *batch* معمولاً نقش *negative sample* را بازی می‌کنند.

| Image x | Augmentation<br>A → x1 | Shared Encoder<br>f | z1 | Pull Together |
|---------|------------------------|---------------------|----|---------------|
|---------|------------------------|---------------------|----|---------------|

SimCLR: دو *view* از یک نمونه باید در فضای *embedding* نزدیک شوند.

| Image x | Augmentation<br>B → x2 | Shared Encoder<br>f | z2 | Pull Together |
|---------|------------------------|---------------------|----|---------------|
|---------|------------------------|---------------------|----|---------------|

### 2.2 Projection Head و Encoder

هر *view* از یک *encoder* مشترک عبور می‌کند. در مقاله اصلی، *encoder* می‌تواند *ResNet* باشد؛ در نسخه‌های جدیدتر هر *backbone* تصویری مانند *ViT* نیز ممکن است. خروجی *encoder* یک *representation h* است. سپس یک شبکه کوچک به نام *h*، *projection head* را به *z* تبدیل می‌کند. *loss contrastive* روی *z* محاسبه می‌شود، اما برای *downstream task* معمولاً *h* را نگه می‌داریم. این جداسازی مهم است: فضایی که برای *objective* پیش‌آموزش مناسب است الزاماً همان فضایی نیست که برای *classification* بهترین است.

### 2.3 Loss چه می‌خواهد؟

برای هر *view*، *anchor* دیگر همان تصویر باید *similarity* بالا داشته باشد و *view*های تصاویر دیگر *similarity* پایین‌تری داشته باشند. معمولاً *cosine similarity* استفاده می‌شود. *NT-Xent / InfoNCE-style loss* به شکل ساده می‌گوید: احتمال انتخاب *positive* واقعی در میان *candidate*ها را زیاد کن. پارامتر *temperature* شدت حساسیت *softmax* به اختلاف *similarity*ها را کنترل می‌کند.

```
sim(i,j) = cosine(z_i, z_j)
loss_i = -log( exp(sim(i,j)/τ) / Σ_k exp(sim(i,k)/τ) )
Goal: positive pair ↑ similarity ; other samples ↓ similarity
```

لازم نیست فرمول را حفظ کنید. مفهوم اصلی این است که embedding باید هویت معنایی پایدار را نگه دارد و تغییرات augmentation را نادیده بگیرد. اگر batch بزرگ باشد، negativeهای بیشتری داریم و مسئله discriminative می‌شود؛ همین موضوع یکی از دلایل نیاز محاسباتی بالای SimCLR کلاسیک است.

## 2.4 بعد از Pretraining چه می‌شود؟

پس از پایان pretraining، projection head معمولاً کنار گذاشته می‌شود. encoder اکنون feature extractor است. می‌توان encoder را freeze کرد و linear classifier ساخت، یا آن را برای task مشخص fine-tune کرد. اگر فقط تعداد کمی label موجود باشد، نقطه قوت SSL آشکار می‌شود: encoder از قبل بسیاری از الگوهای عمومی تصویر را یاد گرفته و classifier جدید لازم نیست همه چیز را از صفر کشف کند.

## 2.5 مثال پاتولوژی

فرض کنید از WSIهای سرطان پستان میلیون‌ها tile داریم ولی فقط بخشی از بیماران label دقیق subtype دارند. برای هر tile دو view می‌سازیم. هدف pretraining این نیست که مدل همان لحظه ILC را تشخیص دهد؛ هدف این است که featureهایی یاد بگیرد که morphology بافت را پایدار نمایش دهند. سپس با داده representation، labeledها برای ILC classification یا retrieval استفاده می‌شوند. در یک پروژه multi-site باید augmentation با احتیاط انتخاب شود تا مدل به artifact یک مرکز نجسبد و در عین حال signal واقعی staining یا morphology را نابود نکند.

**نقطه قوت SimCLR —** مفهوم invariance را بسیار شفاف می‌کند: دو نسخه‌ای که از نظر معنایی «همان نمونه» هستند باید embedding مشابه داشته باشند.

**محدودیت —** اگر augmentation غلط تعریف شود یا negativeها الگوی مسئله را بد نمایش دهند، representation می‌تواند جهت نامناسبی یاد بگیرد. در پزشکی، این انتخاب‌ها باید با منطق دامنه توجیه شوند.

### 3. مثال دوم: Masked Autoencoder (MAE)

MAE از خانواده masked image modeling است. به جای مقایسه دو view، مسئله را این گونه می سازد: «بخش بزرگی از تصویر را از تو پنهان می کنم؛ از بخش باقی مانده ساختار تصویر را یاد بگیر و قسمت های حذف شده را بازسازی کن.» این ایده از موفقیت masking در NLP الهام گرفته، اما برای تصویر با طراحی متناسب با Vision Transformer اجرا می شود.

#### 3.1 تصویر به Patch تقسیم می شود

در ViT، تصویر به patch های کوچک تقسیم و هر patch به یک token تبدیل می شود. فرض کنید 196 patch داریم. MAE می تواند مثلاً حدود 75 درصد patch ها را به صورت تصادفی mask کند و فقط 25 درصد را به encoder بدهد. این نسبت زیاد در ابتدا عجیب به نظر می رسد، اما تصاویر redundancy بالایی دارند؛ اگر فقط 10 درصد مخفی شود، task ممکن است بیش از حد ساده باشد و مدل با interpolation سطحی مسئله را حل کند.

| Image | Patchify | Random Mask ~75% | Encoder: visible tokens | Decoder | Reconstruct masked patches |
|-------|----------|------------------|-------------------------|---------|----------------------------|
|-------|----------|------------------|-------------------------|---------|----------------------------|

MAE: encoder عمدتاً روی patch های قابل مشاهده کار می کند؛ decoder برای بازسازی بخش های حذف شده استفاده می شود.

#### 3.2 چرا Encoder فقط Patch های Visible را می بیند؟

یکی از نکات طراحی MAE efficiency است. چون بخش بزرگی از token ها حذف شده اند، encoder سنگین فقط روی token های باقی مانده اجرا می شود. سپس یک decoder سبک تر token های mask شده را نیز دریافت می کند و تلاش می کند محتوای آن ها را بازسازی کند. در پایان decoder، pretraining معمولاً دور انداخته می شود و encoder نگه داشته می شود. بنابراین هزینه اصلی downstream روی representation encoder متمرکز است.

#### 3.3 Loss چه چیزی را اندازه می گیرد؟

در نسخه کلاسیک، model pixel values مربوط به patch های mask شده را پیش بینی می کند و reconstruction loss روی همان patch های پنهان شده محاسبه می شود. مدل برای کاهش خطا باید از context اطراف استفاده کند. اگر بخشی از ساختار سلولی دیده نشود، باید از نواحی مجاور و الگوهای تصویری بفهمد چه چیزی احتمالاً آنجا وجود دارد. هدف نهایی تولید عکس زیبا نیست؛ بازسازی صرفاً pretext task است که encoder را مجبور می کند structure و context را یاد بگیرد.

#### 3.4 MAE چه نوع Representation می تشویق می کند؟

برخلاف contrastive learning که روی invariance بین view ها تأکید دارد، MAE بیشتر روی contextual understanding و ساختار داخلی ورودی فشار می آورد. مدل باید روابط فضایی patch ها و الگوهای گسترده تر را بفهمد.

این تفاوت باعث می‌شود **contrastive** و **masked modeling** دو فلسفه مکمل باشند. برخی **foundation model**های جدید نیز چند **objective** را ترکیب می‌کنند تا هم **invariance** و هم ساختار محلی/سراسری را بهتر بگیرند.

### 3.5 مثال پاتولوژی

در پاتولوژی، **tile**های **H&E** با **texture** و ساختار مورفولوژیک غنی هستند. اگر بخش بزرگی از یک **tile mask** شود، **encoder** برای کمک به **decoder** باید روابط بین نواحی، توزیع هسته‌ها، **stroma**, **glandular structures** و **context** بافتی را مدل کند. بعداً **encoder** می‌تواند برای **classification**, **clustering** یا **retrieval** استفاده شود. برای **WSI** کامل معمولاً مسئله مقیاس نیز مطرح است؛ مدل‌ها اغلب ابتدا در سطح **tile feature** استخراج می‌کنند و سپس یک **aggregator** یا روش‌هایی مانند **MIL** برای سطح اسلاید به کار می‌رود.

### 3.6 تفاوت با Autoencoder معمولی

**Autoencoder** کلاسیک کل ورودی را **compress** و سپس **reconstruct** می‌کند. **MAE** به طور عمدی بخش زیادی از ورودی را حذف می‌کند و **encoder** اصلاً آن بخش‌ها را نمی‌بیند. بنابراین مدل نمی‌تواند صرفاً یک **identity mapping** ساده یاد بگیرد. **Masking** مسئله را به یک **inference task** تبدیل می‌کند: از **context** محدود، ساختار گمشده را استنتاج کن.

**نقطه قوت MAE —** برای داده تصویری بزرگ و **ViT**ها ساده، مقیاس‌پذیر و مفهومی است: اطلاعات را حذف می‌کند تا مدل مجبور به مدل‌سازی **context** شود.

**محدودیت —** بهینه‌کردن **pixel-level reconstruction** همیشه تضمین نمی‌کند **representation** دقیقاً با مفهوم بالینی مورد نظر هم‌راستا باشد؛ **downstream evaluation** همچنان ضروری است.

## 4. مثال سوم: Self-Distillation با DINO

DINO مخفف Self-Distillation with No Labels است و نمونه مهمی از این ایده است که می‌توان بدون label و بدون تکیه مستقیم بر negative pair ها، representation قدرتمند ساخت. این روش یک student network و یک teacher network دارد. نکته مهم این است که teacher یک مدل از پیش آموزش دیده مستقل نیست؛ در طول training از خود student ساخته و به‌روزرسانی می‌شود.

### 4.1 Teacher و Student چه می‌کنند؟

از یک تصویر چند crop یا view ساخته می‌شود. view های مختلف به student داده می‌شوند و معمولاً teacher نیز view های global را می‌بیند. هر شبکه یک distribution روی feature/prototype dimensions تولید می‌کند. هدف student این است که distribution teacher را برای view های مرتبط تقلید کند. در ظاهر شبیه Knowledge Distillation است، اما هیچ label انسانی و هیچ teacher ثابت و از قبل آموزش دیده‌ای وجود ندارد.

| Image | Multi-crop Views | Student Network | Match Teacher Output | EMA Update → Teacher |
|-------|------------------|-----------------|----------------------|----------------------|
|-------|------------------|-----------------|----------------------|----------------------|

DINO: teacher از میانگین نمایی وزن‌های student به‌روزرسانی می‌شود و target پایدارتر تولید می‌کند.

### 4.2 چگونه به‌روزرسانی می‌شود؟

به جای gradient descent مستقیم روی teacher، وزن‌های آن معمولاً با Exponential Moving Average از student به‌روزرسانی می‌شوند. یعنی teacher نسخه‌ای نرم‌تر و کندتر از تاریخچه student است. اگر  $\theta_s$  وزن student و  $\theta_t$  وزن teacher باشد، ایده کلی چنین است:  $\theta_t \leftarrow m \theta_t + (1 - m) \theta_s$ . مقدار  $m$  معمولاً نزدیک 1 است؛ بنابراین teacher سریع نوسان نمی‌کند و target نسبتاً پایدار ارائه می‌دهد.

### 4.3 پس چرا همه خروجی‌ها یکسان نمی‌شوند؟

این سؤال حیاتی است. اگر student فقط مجبور باشد teacher را تقلید کند و teacher نیز از student ساخته شود، collapse یک خطر جدی است. DINO از مکانیزم‌هایی مثل centering و sharpening در distribution teacher و تفاوت view ها استفاده می‌کند تا خروجی‌ها informative باقی بمانند. جزئیات ریاضی مهم‌اند، اما ایده مفهومی این است که teacher باید targetی با entropy و توزیع کنترل شده بسازد، نه اینکه برای همه تصاویر پاسخ ثابت بدهد.

### 4.4 چرا DINO برای Vision Transformer مهم شد؟

یکی از یافته‌های جالب DINO این بود که ViT های self-supervised می‌توانند attention map ها و feature های بسازند که ساختار اشیا را بدون supervision صریح نشان دهند. این نتیجه باعث شد DINO و نسل‌های بعدی آن برای representation learning تصویری بسیار تأثیرگذار شوند. DINOv2 این مسیر را در مقیاس بزرگ‌تر ادامه داد و بر

ساخت featureهای عمومی و robust تمرکز کرد. البته DINOv2 دقیقاً «فقط DINO بزرگ‌تر» نیست؛ pipeline داده و objectiveهای آن جزئیات بیشتری دارد.

## 4.5 کاربرد بالقوه در پاتولوژی

در pathology، self-distillation جذاب است زیرا می‌توان viewهای مختلف یک tile یا cropهای چندمقیاسی را بدون label معنایی به هم مرتبط کرد. مدل می‌تواند consistency بین نگاه‌های مختلف به یک ساختار بافتی را یاد بگیرد. در پروژه‌های foundation model، چنین featureهایی بعداً برای retrieval، clustering، classification یا به عنوان ورودی aggregator سطح اسلاید استفاده می‌شوند. مزیت دیگر این است که وابستگی به negative sampling کلاسیک کاهش پیدا می‌کند؛ هرچند طراحی training همچنان حساس است.

## 4.6 ارتباط DINO با Knowledge Distillation

در Knowledge Distillation معمولی، teacher غالباً یک مدل بزرگ و آموزش دیده است و student می‌خواهد رفتار آن را تقلید کند. در DINO، teacher و student در یک فرایند self-supervised مشترک رشد می‌کنند و teacher با EMA student به‌روزرسانی می‌شود. بنابراین DINO نمونه‌ای از self-distillation است: دانش از یک نسخه پایدارتر خود مدل به نسخه در حال یادگیری منتقل می‌شود، بدون label خارجی.

**نقطه قوت DINO —** برای فهم این نکته عالی است که SSL الزاماً reconstruction یا negative pair نمی‌خواهد؛ می‌توان target را از teacher پویای خود مدل ساخت.

**محدودیت —** جزئیات جلوگیری از collapse، schedule، augmentation و تنظیم teacher/student اهمیت زیادی دارند؛ اجرای ساده و بدون این اجزا می‌تواند شکست بخورد.

## 5. مثال چهارم: BERT در Masked Language Modeling

برای اینکه روشن شود SSL محدود به Computer Vision نیست، بهترین مثال Masked Language Modeling در BERT است. در اینجا داده، جمله‌های متنی بدون label هستند. مدل به جای دریافت برجسب sentiment یا topic، بخشی از token‌ها را مخفی می‌کند و باید token اصلی را از context پیش‌بینی کند. target مستقیماً از جمله اولیه می‌آید.

### 5.1 ساخت مسئله آموزشی از یک جمله

فرض کنید جمله انگلیسی چنین باشد: "The patient has breast cancer". اگر token مربوط به "breast" مخفی شود، ورودی می‌تواند "The patient has [MASK] cancer" باشد و target همان token اصلی یعنی "breast" است. هیچ annotator ننوشته است که جواب چیست؛ داده خام جواب را از ابتدا در خود داشته است و فرایند masking فقط آن را موقتاً از مدل پنهان کرده است.

| Original Sentence | Mask Tokens | Transformer Encoder | Predict Missing Token | Cross-Entropy Loss |
|-------------------|-------------|---------------------|-----------------------|--------------------|
|-------------------|-------------|---------------------|-----------------------|--------------------|

BERT/MLM: خود token حذف‌شده label آموزشی را فراهم می‌کند.

### 5.2 مدل چه چیزی یاد می‌گیرد؟

برای پیش‌بینی token گمشده، مدل باید به کلمات قبل و بعد توجه کند و روابط نحوی و معنایی را بفهمد. اگر فقط یک lookup ساده داشته باشد، در جمله‌های متنوع شکست می‌خورد. به مرور، hidden representation‌های Transformer اطلاعاتی درباره semantics، context و روابط بین token‌ها حمل می‌کنند. این representation‌ها بعداً برای classification، named-entity recognition، question answering و بسیاری task‌های دیگر fine-tune می‌شوند.

### 5.3 چرا این واقعاً Self-Supervised است؟

چون pair ورودی-target به صورت خودکار از یک متن خام ساخته شده است. اگر میلیاردها جمله داشته باشیم، می‌توانیم میلیاردها تمرین masking بسازیم بدون اینکه انسان برای هر جمله label تولید کند. این دقیقاً همان منطق MAE است، فقط modality متفاوت است: در BERT token‌های زبان mask می‌شوند؛ در MAE patch‌های تصویر. هر دو از context برای پیش‌بینی بخش پنهان استفاده می‌کنند.

### 5.4 تفاوت با Autoregressive Language Modeling

در مدل autoregressive مانند GPT، هدف معمولاً پیش‌بینی token بعدی بر اساس token‌های قبلی است. این نیز یک objective self-supervised است، چون target از متن خام می‌آید. تفاوت اصلی در ساختار پیش‌بینی است: BERT در pretraining کلاسیک می‌تواند از context دوطرفه اطراف token mask‌شده استفاده کند، در حالی که مدل

autoregressive به صورت causal آینده را نمی بیند و next-token prediction انجام می دهد. هر دو نشان می دهند SSL یک اصل عمومی است، نه تکنیکی مخصوص تصویر.

## 5.5 نتیجه‌ای که برای سایر modalities باید بگیریم

هر جا داده ساختار داخلی داشته باشد، می توان به دنبال یک pretext objective بود: در graph می توان node/edge attributes را mask کرد، subgraphها را مقایسه کرد یا context همسایگی را پیش بینی کرد؛ در audio می توان بخش هایی از waveform یا latent units را پنهان و پیش بینی کرد؛ در time series می توان future/context یا augmented viewهای را مدل کرد. بنابراین SSL به CNN، ViT یا Transformer خاصی وابسته نیست. سؤال اصلی این است: «چه رابطه‌ای در داده وجود دارد که بتوانیم بدون label انسانی آن را به یک task آموزشی تبدیل کنیم؟»

**نقطه قوت این مثال — BERT** نشان می دهد تعریف SSL بر اساس منبع target است، نه نوع داده. همان منطق masking می تواند از زبان به تصویر، صوت، سری زمانی و گراف منتقل شود.

## 6. این مفاهیم در Pathology Foundation Models چگونه کنار هم قرار

### می گیرند؟

برای موقعیت هایی مانند foundation model های پاتولوژی، مهم است SSL را نه به عنوان یک الگوریتم منفرد، بلکه به عنوان بخشی از کل pipeline ببینید. Whole-Slide Image ها بسیار بزرگ اند و معمولاً مستقیماً به یک encoder معمولی داده نمی شوند. یک workflow متداول می تواند به شکل زیر باشد؛ جزئیات دقیق هر پروژه متفاوت است.

| WSI | Tissue Detection / Tiling | SSL or Pretrained FM | Tile Embeddings | Slide Aggregation | Clinical Task |
|-----|---------------------------|----------------------|-----------------|-------------------|---------------|
|-----|---------------------------|----------------------|-----------------|-------------------|---------------|

نمونه مفهومی از pipeline پاتولوژی؛ این نمودار نسخه عمومی است و نه الزاماً معماری یک پروژه خاص.

### 6.1 مرحله Tile و Representation

ابتدا از نواحی بافتی tile، WSI یا patch استخراج می شود. سپس یک encoder pretrained – که ممکن است با tile embedding، masked modeling، self-distillation، contrastive learning یا ترکیبی از آن ها آموزش دیده باشد – برای هر tile foundation model از قبل روی حجم بزرگی از pathology data آموزش دیده باشد، ممکن است مستقیماً feature extraction انجام شود یا model برای داده هدف adapt شود.

## 6.2 Fine-tuning و Parameter-Efficient Fine-Tuning

اگر مدل بسیار بزرگ باشد، fine-tune کردن همه پارامترها همیشه لازم یا عملی نیست. در PEFT فقط بخش کوچکی از پارامترها یا adapterها تغییر می‌کنند. مزیت آن کاهش هزینه محاسباتی و حافظه و گاهی کاهش overfitting در dataset کوچک است. نکته مهم این است که PEFT خود SSL نیست؛ روش SSL، pretraining/learning signal است، در حالی که PEFT روش adaptation یک مدل pretrained برای task جدید است.

### 6.3 از Slide به Tile: چرا MIL مطرح می‌شود؟

در بسیاری از مسائل label، WSI در سطح slide یا patient وجود دارد اما برای تک تک tileها label نداریم. Multiple-Instance Learning یک چارچوب رایج برای aggregate کردن مجموعه‌ای از tile embeddingها و پیش‌بینی label سطح بالاتر است. SSL و MIL دو مفهوم متفاوت ولی مکمل‌اند: SSL encoder را بدون label دقیق pretrain می‌کند؛ MIL می‌تواند embeddingهای tile را برای prediction سطح slide ترکیب کند.

### 6.4 Robustness بین مرکزها

در پروژه multi-site، تصویرها ممکن است با scanner، staining protocol یا preparation متفاوت تولید شوند. SSL به‌خودی‌خود robustness را تضمین نمی‌کند. باید طراحی augmentation، composition، pretraining، normalization و external validation طوری باشد که مدل به confounderهای مرکز وابسته نشود. بهترین نشانه robustness این است که performance روی بیمارستان یا cohortی که در training ندیده‌ایم نیز حفظ شود.

### 6.5 چگونه بفهمیم Pretraining واقعاً مفید بوده؟

- Linear probing: encoder ثابت، classifier ساده؛ سنجش کیفیت خام representation.
- Fine-tuning: سنجش اینکه representation با adaptation چقدر به task هدف منتقل می‌شود.
- Retrieval: آیا نمونه‌های morphologically/clinically مرتبط در embedding space نزدیک‌اند؟
- Clustering: آیا structure طبیعی داده در feature space ظاهر می‌شود؟
- External validation: آیا feature و مدل در cohort یا مرکز دیگر پایدار هستند؟
- Ablation: مقایسه با initialization تصادفی یا supervised baseline برای اینکه اثر واقعی pretraining مشخص شود.

**تفکیک مفهومی مهم —** SSL = روش ساخت سیگنال pretraining. Foundation Model = مدل بزرگ و قابل انتقال که معمولاً با داده گسترده pretrain شده است. Fine-tuning/PEFT = روش سازگار کردن مدل با task جدید. MIL = روش aggregate کردن instanceها، مثلاً tileهای یک WSI.

## 7. مقایسه چهار مثال در یک نگاه

| نکته کلیدی                               | ایده اصلی                | Target از کجا می‌آید؟       | چه چیزی پنهان/تغییر می‌کند؟       | روش      |
|------------------------------------------|--------------------------|-----------------------------|-----------------------------------|----------|
| Invariance بین viewها                    | Contrastive similarity   | رابطه «این دو یک نمونه‌اند» | دو augmentation از یک تصویر       | SimCLR   |
| فهم ساختار برای بازسازی                  | Reconstruction / context | patchهای واقعی حذف شده      | بخش بزرگی از patchها mask می‌شوند | MAE      |
| Consistency بدون label و negative کلاسیک | Self-distillation        | خروجی teacher پویا          | چند view؛ teacher/student         | DINO     |
| Contextual representation در زبان        | Masked prediction        | token اصلی متن              | برخی tokenها mask می‌شوند         | BERT MLM |

### 7.1 برای انتخاب روش، چه سؤالاتی پرسیم؟

1. چه invarianceهایی واقعاً معتبرند؟ اگر دو augmentation باید از نظر معنایی یک چیز باشند، -contrastive/self-distillation مناسب‌تر می‌شود.
2. آیا ساختار داخلی ورودی اطلاعات زیادی برای پیش‌بینی بخش گمشده دارد؟ اگر بله، masked modeling طبیعی است.
3. آیا negative sample قابل تعریف و قابل اعتماد است؟ اگر نه، روش‌های non-contrastive یا self-distillation جذاب‌تر می‌شوند.
4. مقیاس داده و compute چقدر است؟ برخی روش‌ها batch بزرگ یا training طولانی می‌خواهند.
5. Downstream task چیست؟ بهترین pretraining objective باید با اطلاعات مورد نیاز task نهایی هم‌راستا باشد.

### 7.2 چند سوءبرداشت رایج

| اصلاح                                                                                | سوءبرداشت                               |
|--------------------------------------------------------------------------------------|-----------------------------------------|
| غلط؛ target وجود دارد، اما از خود داده ساخته می‌شود.                                 | SSL یعنی مدل بدون target آموزش می‌بیند. |
| غلط؛ در متن، صوت، گراف، ویدئو و سری زمانی هم استفاده می‌شود.                         | SSL فقط برای تصاویر است.                |
| غلط؛ foundation model به مقیاس، قابلیت انتقال و دامنه استفاده گسترده‌تری اشاره دارد. | هر Autoencoder یک Foundation Model است. |

|                                                                                     |                                          |
|-------------------------------------------------------------------------------------|------------------------------------------|
| غلط؛ بسیاری از downstream task ها برای fine-tuning و ارزیابی هنوز label نیاز دارند. | اگر SSL خوب باشد دیگر label لازم نیست.   |
| غلط؛ کیفیت داده، objective، augmentation و domain shift تعیین کننده اند.            | SSL همیشه generalization را بهتر می کند. |

## 8. واژه نامه مفهومی

| معنی عملی                                                                                        | اصطلاح                     |
|--------------------------------------------------------------------------------------------------|----------------------------|
| مسئله ای که برای pretraining ساخته می شود؛ مثلاً بازسازی patch یا تطبیق دو view. هدف نهایی نیست. | Pretext Task               |
| مسئله واقعی پس از pretraining؛ مثل classification، segmentation، prognosis یا retrieval.         | Downstream Task            |
| بردار یا featureهایی که encoder از ورودی استخراج می کند و اطلاعات مهم را فشرده می کند.           | Representation / Embedding |
| بخشی از مدل که داده خام را به feature/representation تبدیل می کند.                               | Encoder                    |
| شبکه کوچک روی encoder در برخی contrastive methods که loss pretraining روی خروجی آن اعمال می شود. | Projection Head            |
| دو نمونه/view که باید از نظر representation نزدیک تلقی شوند.                                     | Positive Pair              |
| نمونه هایی که در برخی contrastive objectives باید از هم متمایز شوند.                             | Negative Pair              |
| پنهان کردن بخشی از ورودی و استفاده از بخش اصلی به عنوان target.                                  | Masking                    |
| freeze کردن encoder و آموزش یک classifier خطی برای سنجش کیفیت representation.                    | Linear Probe               |
| به روزرسانی بخشی یا همه وزن های مدل pretrained روی task جدید.                                    | Fine-tuning                |
| سازگار کردن مدل با تغییر تعداد کمی پارامتر؛ مثلاً adapters یا LoRA در معماری های مناسب.          | PEFT                       |

|                         |                                                                            |
|-------------------------|----------------------------------------------------------------------------|
| EMA Teacher             | teacherای که وزن هایش با میانگین نمایی وزن های student به روزرسانی می شود. |
| Representation Collapse | وضعیتی که مدل برای ورودی های مختلف featureهای تقریباً یکسان تولید می کند.  |
| External Validation     | ارزیابی روی cohort/مرکز مستقلی که در training استفاده نشده است.            |

## 9. تست مفهومی کوتاه

1. اگر label انسانی نداریم، SSL چگونه loss محاسبه می کند؟
2. چرا دو augmentation در SimCLR positive pair هستند؟
3. چرا projection head در SimCLR معمولاً برای downstream کنار گذاشته می شود؟
4. چرا MAE درصد زیادی از patch ها را mask می کند؟
5. DINO چه تفاوتی با knowledge distillation کلاسیک دارد؟
6. Representation collapse یعنی چه؟
7. چرا PEFT و SSL یک مفهوم نیستند؟
8. در target، BERT دقیقاً از کجا می آید؟
9. چرا external validation در pathology حتی با SSL همچنان ضروری است؟

**پیشنهاد مطالعه —** قبل از رفتن به صفحه پاسخ ها، تلاش کنید هر سؤال را با 2 تا 4 جمله و بدون نگاه کردن به متن توضیح دهید. اگر نتوانستید، آن مفهوم هنوز به سطح «قابل توضیح در مصاحبه» نرسیده است.

## 10. پاسخ تست مفهومی

1. Target به صورت خودکار از داده یا تبدیل های آن ساخته می شود؛ مثلاً token واقعی، patch حذف شده یا رابطه بین دو view.
2. چون هر دو از یک نمونه اصلی تولید شده اند و فرض می کنیم augmentation هویت معنایی اصلی را تغییر نداده است.
3. Projection head عمدتاً فضای مناسب برای contrastive objective را می سازد؛ feature encoder معمولاً برای انتقال به task های دیگر عمومی تر است.

4. Masking زیاد task را سخت و غیرمحملی می‌کند و encoder را مجبور می‌کند از context و ساختار کلی استفاده کند، نه صرفاً interpolation ساده.

5. در distillation کلاسیک teacher معمولاً از قبل آموزش دیده و ثابت/قوی‌تر است؛ در DINO teacher از EMA خود student ساخته می‌شود و training بدون label است.

6. وقتی representation‌های ورودی‌های مختلف به یک خروجی ثابت یا تقریباً ثابت فرو می‌ریزند و دیگر اطلاعات discriminative ندارند.

7. SSL درباره منبع supervision در pretraining است؛ PEFT درباره اینکه هنگام adaptation چه تعداد پارامتر را تغییر دهیم.

8. از همان متن خام؛ token اصلی قبل از masking, target prediction است.

9. چون scanner, staining, cohort و مرکز می‌توانند domain shift و confounding ایجاد کنند. SSL تضمین‌کننده generalization بالینی نیست.

## 11. چک‌لیست: اگر SSL را فهمیده باشید، باید بتوانید این‌ها را توضیح دهید

- تفاوت label انسانی و self-generated target را با یک مثال روشن بیان کنید.
- Pretraining, representation و downstream task را بدون استفاده از تعریف حفظی توضیح دهید.
- فرق self-distillation و contrastive learning, masked modeling را بگویید.
- توضیح دهید SimCLR چرا به augmentation و similarity نیاز دارد.
- توضیح دهید MAE چرا masking بالا انجام می‌دهد و چرا decoder معمولاً دور انداخته می‌شود.
- توضیح دهید DINO چگونه teacher می‌سازد و چرا collapse مسئله است.
- با مثال BERT نشان دهید SSL محدود به تصویر نیست.
- در یک پروژه pathology توضیح دهید SSL کجای pipeline قرار می‌گیرد و چرا external validation مهم است.

## 12. منابع پیشنهادی برای مطالعه عمیق‌تر

1. Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A Simple Framework for Contrastive Learning of Visual Representations (SimCLR). ICML.
2. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. CVPR.
3. Caron, M., Touvron, H., Misra, I., et al. (2021). Emerging Properties in Self-Supervised Vision Transformers (DINO). ICCV.
4. Oquab, M., Darcet, T., Moutakanni, T., et al. (2023). DINOv2: Learning Robust Visual Features without Supervision. arXiv.

5. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.
6. He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum Contrast for Unsupervised Visual Representation Learning (MoCo). CVPR.
7. Grill, J.-B., Strub, F., Altché, F., et al. (2020). Bootstrap Your Own Latent (BYOL). NeurIPS.
8. Bardes, A., Ponce, J., & LeCun, Y. (2022). VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning. ICLR.

## 13. جمع‌بندی نهایی در پنج خط

1. Self-Supervised Learning از خود داده target می‌سازد؛ بنابراین برای pretraining به label انسانی وابسته نیست.
2. محصول اصلی معمولاً یک representation/encoder قابل انتقال است، نه حل کردن pretext task به عنوان هدف نهایی.
3. SimCLR با similarity بین viewها، MAE با بازسازی بخش mask شده، DINO با self-distillation و BERT با masked token prediction یاد می‌گیرند.
4. SSL معماری‌محور نیست: در image, text, audio, graph, video و time series قابل استفاده است.
5. در Medical AI و pathology، ارزش SSL در استفاده از داده بدون annotation زیاد است؛ اما، robustness، external validation و alignment با task بالینی همچنان ضروری‌اند.

**اگر برای مصاحبه فقط یک پاسخ 30 ثانیه‌ای بخواهید —** Self-supervised learning روشی برای pretraining روی داده‌های بدون label انسانی است که در آن target از خود داده ساخته می‌شود؛ مثلاً دو augmentation از یک تصویر را نزدیک می‌کنیم، patchهای mask شده را بازسازی می‌کنیم یا student خروجی teacher خودکار را تقلید می‌کند. هدف اصلی یادگیری representation عمومی است که بعداً با داده labeled برای taskهایی مثل classification, retrieval یا prognosis fine-tune یا ارزیابی می‌شود.